

Übungsblatt 5 — Inferenz im einfachen Regressionsmodell

Aufgabe 3 — Anwendungsbeispiel: Hauspreise

Der Datensatz `br.dat` (Variablenbeschreibung in `br.def`) enthält die Daten von 1080 verkauften Häusern im Ort Baton Rouge für das Jahr 2005.

- (a) Schätzen Sie die Koeffizienten aus dem Regressionsansatz $\text{Price} = \beta_0 + \beta_1 \text{Age} + \epsilon$ und konstruieren Sie ein 95%-Konfidenzintervall für den unbekannten Koeffizienten β_1 .

Zunächst lesen wir die Daten ein. Die Funktion `read.table()` erzeugt ein Objekt des Typs `data.frame`. Da die Datei `br.dat` keine Variablennamen enthält, weisen wir diese manuell zu (siehe `br.def` für eine Beschreibung des Datensatzes). Wir ändern hierzu die Spaltennamen von `baton` mit der Funktion `colnames()`.

```
# Der Datensatz 'br.dat' ist in Moodle verfügbar
# (ggf. korrektes Arbeitsverzeichnis setzen)
# Daten einlesen; erzeugt einen data.frame:
# baton <- read.table("br.dat")

# Ist 'baton' ein data.frame?
is.data.frame(baton)
```

```
[1] TRUE
```

```
# Variablennamen gem. der Beschreibung setzen
colnames(baton) <- c("Price", "sqft", "Bedrooms",
                    "Baths", "Age", "Occupancy",
                    "Pool", "Style", "Fireplace",
                    "Waterfront", "DOM")

# Ueberblick
head(baton)
```

	Price	sqft	Bedrooms	Baths	Age	Occupancy	Pool	Style	Fireplace	Waterfront	DOM
1	66500	741	1	1	18		1	1	1	0	6
2	66000	741	1	1	18		2	1	1	0	23
3	68500	790	1	1	18		1	0	1	1	8
4	102000	2783	2	2	18		1	0	1	1	50
5	54000	1165	2	1	35		2	0	1	0	190
6	143000	2331	2	2	25		1	0	1	1	86

```
# statistische Zusammenfassung
summary(baton)
```

Price	sqft	Bedrooms	Baths
Min. : 22000	Min. : 662	Min. : 1.00	Min. : 1.000
1st Qu.: 99000	1st Qu.: 1604	1st Qu.: 3.00	1st Qu.: 2.000
Median : 130000	Median : 2186	Median : 3.00	Median : 2.000
Mean : 154863	Mean : 2326	Mean : 3.18	Mean : 1.973
3rd Qu.: 170162	3rd Qu.: 2800	3rd Qu.: 4.00	3rd Qu.: 2.000
Max. : 1580000	Max. : 7897	Max. : 8.00	Max. : 5.000

Age	Occupancy	Pool	Style
Min. : 1.00	Min. : 1.000	Min. : 0.00000	Min. : 1.000
1st Qu.: 5.00	1st Qu.: 1.000	1st Qu.: 0.00000	1st Qu.: 1.000
Median : 18.00	Median : 2.000	Median : 0.00000	Median : 1.000
Mean : 19.57	Mean : 1.565	Mean : 0.07963	Mean : 3.753
3rd Qu.: 25.00	3rd Qu.: 2.000	3rd Qu.: 0.00000	3rd Qu.: 7.000
Max. : 80.00	Max. : 3.000	Max. : 1.00000	Max. : 11.000

Fireplace	Waterfront	DOM
Min. : 0.000	Min. : 0.00000	Min. : 0.00
1st Qu.: 0.000	1st Qu.: 0.00000	1st Qu.: 14.00
Median : 1.000	Median : 0.00000	Median : 40.00
Mean : 0.563	Mean : 0.07222	Mean : 74.06
3rd Qu.: 1.000	3rd Qu.: 0.00000	3rd Qu.: 100.25
Max. : 1.000	Max. : 1.00000	Max. : 728.00

```
# Modell schätzen
mod <- lm(Price ~ Age, data = baton)
mod
```

Call:
lm(formula = Price ~ Age, data = baton)

Coefficients:
(Intercept) Age
184053 -1491

```
# Statistischer Zusammenfassung der Schätzung
summary(mod)
```

Call:
lm(formula = Price ~ Age, data = baton)

Residuals:
 Min 1Q Median 3Q Max
-117210 -54383 -27562 16930 1415333

Coefficients:
 Estimate Std. Error t value Pr(>|t|)
(Intercept) 184052.8 5546.5 33.183 < 2e-16 ***
Age -1491.2 212.9 -7.003 4.39e-12 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 120300 on 1078 degrees of freedom
Multiple R-squared: 0.04352, Adjusted R-squared: 0.04263
F-statistic: 49.05 on 1 and 1078 DF, p-value: 4.392e-12

```
# Genauere Ergebnisse erhalten wir durch Auslesen der
# Koeffizienten mit coef()
coef(mod)
```

```
(Intercept)      Age
184052.764    -1491.237
```

Wir berechnen das Konfidenzintervall zunächst per Hand. Hierzu verwenden wir die Statistiken aus dem Output von `summary(mod)` weiter oben.

Für das 95%-Konfidenzintervall für $\hat{\beta}_1$ benutzen wir die Formel

$$95\text{-KI} = \left[\hat{\beta}_1 - \text{KritischerWert}(5\%) \cdot SE(\hat{\beta}_1), \hat{\beta}_1 + \text{KritischerWert}(5\%) \cdot SE(\hat{\beta}_1) \right]$$

von Folie 4-16 der VL. Wir verwenden zunächst den kritischen Wert der t -Verteilung mit $n - 2$ Freiheitsgraden.

```
#### Das 95%-KI per Hand berechnen ####
n <- nrow(baton)           # Anzahl Beobachtungen
k <- 2                     # Anzahl der Regressoren + Konstante
alpha <- 0.05              # Signifikanzniveau
t.factor <- qt(p = 1-alpha/2, df = n-2) # 1 - alpha/2 Quantil der t-Verteilung
baton.coef <- summary(mod)$coefficients # Koeffizientenmatrix
b.dach <- baton.coef[2, 1]  # Schätzung des Koeffizienten
b.err <- baton.coef[2, 2]   # Standardfehler des Schätzers

# Intervall berechnen:
c(b.dach - t.factor * b.err, b.dach + t.factor * b.err)
```

```
[1] -1909.047 -1073.427
```

Praktischer ist die Funktion `confint()`, welche genau diese Berechnung für uns durchführt:

```
# Mit 'confint()' das 95%-KI für Koeffizienten von 'Age' berechnen
confint(mod, parm = "Age")
```

```
      2.5 %      97.5 %
Age -1909.047 -1073.427
```

Wie bei der Funktion `t.test()` rechnet `confint()` mit dem 97.5%-Quantil der entsprechenden t -Verteilung. Wir können 1.96, das 97.5%-Quantil der Standardnormalverteilung verwenden, da die t -Verteilung für $n - k = 1080 - 2 = 1078$ Freiheitsgrade sehr gut durch die Standardnormalverteilung approximiert wird (s. Folie 4-10 ff.), d.h. wir approximieren 1.962167 mit 1.96 (Vergleich `qt(0.975, df = 1078)` und `qnorm(0.975)`).

Per Hand:

```
# 95%-KI wenn Standardnormalverteilung unterstellt wird:
c(b.dach - 1.96 * b.err, b.dach + 1.96 * b.err)
```

```
[1] -1908.586 -1073.889
```

Die beiden Intervalle sind tatsächlich sehr ähnlich.

- (b) Testen Sie die Nullhypothese, dass ein zusätzliches Jahr im Alter des Hauses zu einer Reduktion des Preises um 1000 Dollar führt. Bestimmen Sie dazu den p -Wert des geeigneten zweiseitigen t -Tests.

Wir können R nutzen, um mit den berechneten Größen (t-Statistik / p-Wert) zu überprüfen, ob $H_0 : \beta_1 = -1000$ zum Signifikanzniveau 5% abgelehnt wird:

```
## Test per Hand durchführen
# Nullhypothese
Age.H0 <- -1000

# Teststatistik
t.Stat <- (b.dach - Age.H0)/b.err
```

Wir berechnen den p -Wert für den Test gem. den Erläuterungen auf Folie 4-10.

```
# P-Wert (t-Verteilung mit 1078 Freiheitsgraden wird unterstellt)
p.Wert <- 2 * (1 - pt(abs(t.Stat), df = n - k))
p.Wert
```

```
[1] 0.02124343
```

Hypothesentest durchführen...

...durch Vergleich mit kritischem Wert (liegt die Teststatistik im Ablehnbereich?)

```
abs(t.Stat) >= t.factor
```

```
[1] TRUE
```

```
# => Wir lehnen H_0: beta_1 = -1000 ab!
```

...mit dem p-Wert: ist dieser kleiner als das Signifikanzniveau $\alpha = 0.05$?

```
p.Wert <= 0.05
```

```
[1] TRUE
```

```
# => Wir lehnen H_0: beta_1 = -1000 ab!
```

Da $p = 0.02124 \leq \alpha = 0.05$ kann die Nullhypothese $H_0 : \beta_1 = -1000$ also zum Signifikanzniveau 5% verworfen werden.

Exkurs:

Für den Hypothesentest können wir die Funktion `linearHypothesis()` benutzen. Diese ist Bestandteil des Pakets `AER`.

```
# Paket AER installieren
# install.packages("AER") # einmalig

# Paket AER laden
library(AER) # jedes mal, wenn R neu gestartet wird

# Hypothesentest mit linearHypothesis() durchführen
linearHypothesis(mod, "Age = -1000")
```

Linear hypothesis test

Hypothesis:
Age = - 1000

Model 1: restricted model
Model 2: Price ~ Age

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	1079	1.5669e+13				
2	1078	1.5592e+13	1	7.6979e+10	5.3223	0.02124 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Die Teststatistik hat den Wert 5.3223. Auch hier beträgt der p -Wert etwa 0.02124. Auch hier argumentieren wir, dass die Nullhypothese abgelehnt wird, denn $p = 0.02124 < \alpha = 0.05$.

Genauer führt `linearHypothesis()` keinen t -Test, sondern einen F -Test durch:

Unter der Annahme $H_0 : \beta_1 = \beta_{1,0}$ und normalverteilter KQ-Schätzer ist

$$t\text{-Statistik} = \left[\hat{\beta}_1 - \beta_{1,0} \right] / SE(\hat{\beta}_1) \sim t_{n-k},$$

d.h. die t -Statistik ist t -verteilt mit $n - k$ Freiheitsgraden, und es gilt

$$F\text{-Statistik} = \left[\frac{\hat{\beta}_1 - \beta_{1,0}}{SE(\hat{\beta}_1)} \right]^2 \sim F_{1,n-k},$$

wobei $F_{1,n-k}$ die F -Verteilung mit Zählerfreiheitsgrad 1 und Nennerfreiheitsgraden $n - k$ ist.

Für die Teststatistik der Hypothese $H_0 : \beta_1 = -1000$ mit $n = 1080$ und $k = 2$ folgt also

$$\left[\frac{\hat{\beta}_1 - (-1000)}{SE(\hat{\beta}_1)} \right]^2 \sim F_{1,1078}.$$

Aufgrund des Quadrates sind Realisationen der Teststatistiken nicht-negativ. Wir lehnen ab, wenn die Teststatistik den kritischen Wert in der rechten Flanke der $F_{1,1078}$ -Verteilung *überschreitet*.

```
# kritischer Wert der F_1,1078-Verteilung für alpha = 0.05
qf(0.95, df1 = 1, df2 = 1078)
```

[1] 3.850099

Die Grafik unten zeigt die Dichtefunktion der $F_{1,1078}$ -Verteilung sowie den Ablehnbereich für einen Test zum Signifikanzniveau $\alpha = 0.05$. Offenbar liegt 5.3223, der Wert unserer Teststatistik, im Ablehnbereich, sodass $H_0 : \beta_1 = -1000$ zum 5%-Niveau angelehnt wird.

```
# Dichtefunktion der F_1,1078-Verteilung zeichnen
curve(df(x, df1 = 1, df2 = 1078),
      yaxs = "i",
      cex.lab = 0.75,
      cex.axis = 0.75,
      lwd = 2,
      from = 0,
      to = 6,
      xlab = "Quadrierte t-Statistik bei n=1080 und k=2",
      ylab = "Dichte der F(1,1078)-Verteilung")

# Kritischen Wert berechnen
kritWert <- qf(0.95, df1 = 1, df2 = 1078)

# Ablehnbereich in die Grafik einzeichnen
lines(x = seq(kritWert, 7, length.out = 60), y = rep(0.01, 60), col = "red", lwd = 5)
```

