

## Übungsblatt 6 — Inferenz in Regressionsmodellen I

Zu diesem Übungsblatt empfehlen wir neben der Lektüre von Kapitel 5 des Lehrbuches *Introduction to Econometrics* von *Stock & Watson* eine Aufarbeitung mithilfe der Kapitel 5 in unserem Online-Companion *Introduction to Econometrics with R*.

### Aufgabe 1 — Anwendungsbeispiel: Boston Housing Data

Das Paket **MASS** enthält den Datensatz **Boston**, welcher wiederum die Variable **medv** (median house value) für 506 Gemeinden rund um Boston enthält. Im folgenden wollen wir ein lineares Modell aufstellen mit **medv** als abhängiger Variable und bis zu 13 erklärenden Variablen. Diese sind z. B. **rm** (average number of rooms per house), **age** (average age of houses), und **lstat** (percent of households with low socioeconomic status).

- (a) Verschaffen Sie sich einen Überblick über den Datensatz.
- (b) Passen Sie ein einfaches lineares Modell an mit **medv** als abhängiger und **lstat** als erklärender Variable. Geben Sie die  $p$ -Werte und die Standardfehler der geschätzten Koeffizienten an. Berechnen Sie auch das  $R^2$  und die  $F$ -Statistik für das Modell.
- (c) Berechnen Sie ein 90%-Konfidenzintervall für die geschätzten Koeffizienten.
- (d) Schätzen Sie die Werte von **medv** für den Fall, dass die Variable **lstat** die Werte 5, 10 und 15 annimmt.
- (e) Plotten Sie **medv** und **lstat** zusammen mit der geschätzten Regressionsgerade.
- (f) Wiederholen Sie die Aufgaben (b) und (c) unter Verwendung heteroskedastie-robuster Standardfehler. Ausführliche Erläuterungen zur Berechnung heteroskedastie-robuster Standardfehler in Regressionsmodellen mit Anwendungsbeispielen in **R** finden Sie in Kapitel 5.4 im Online-Companion.
- (g) Passen Sie ein Regressionsmodell an, welches **lstat** und **age** als erklärende Variablen für **medv** enthält.
- (h) Passen Sie ein Regressionsmodell an, welches **medv** auf alle 13 Variablen regressiert.
- (i) Passen Sie ein Regressionsmodell an, welches **medv** auf alle Variablen im Datensatz außer **age** regressiert.
- (j) Wiederholen Sie die Aufgabenteile (g) - (i) unter Verwendung bei Heteroskedastie gültiger Standardfehler.

### Aufgabe 2 — Bew. zur Stichprobenverteilung von $\hat{\beta}_1$

Diese Aufgaben dient dazu die behauptete erste Gleichung auf Folie 3-53 nachzuweisen. Betrachten Sie das Regressionsmodell

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \quad i = 1, \dots, n.$$

Zeigen Sie, dass für den KQ-Schätzer  $\hat{\beta}_1$  gilt:

$$\hat{\beta}_1 - \beta_1 = \frac{\sum_{i=1}^n (X_i - \bar{X}) u_i}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

### Aufgabe 3 — Anwendungsbeispiel: Lohnregression II

Aus Daten einer Stundenlohnerhebung (in Euro) von 250 zufällig ausgewählten Männern und 280 nicht-männlichen Personen, errechnete ein Wissenschaftler folgendes Regressionsergebnis:

$$\widehat{Lohn} = \underset{(0.23)}{12.52} + \underset{(0.36)}{2.12} \times Mann, \quad R^2 = 0.06, \quad SER = 4.2,$$

wobei *Mann* eine binäre Variable ist mit  $Mann = 1$ , falls die Person männlich ist, und  $Mann = 0$ , falls nicht. Definiere die Lohngeschlechterdifferenz als die Differenz des durchschnittlichen Stundenlohns zwischen Männern und anderen Geschlechtern.

- (a) Wie hoch ist die geschätzte Lohngeschlechterdifferenz?
- (b) Ist die Lohngeschlechterdifferenz signifikant von 0 verschieden auf einem Niveau von 1%? Benutzen Sie für Ihre Antwort den  $p$ -Wert.
- (c) Konstruieren Sie ein 95%-Konfidenzintervall für die Lohngeschlechterdifferenz.
- (d) Was ist der Durchschnittslohn der Geschlechtergruppen im Datensatz?
- (e) Ein anderer Wissenschaftler benutzt dieselben Daten, aber er regressiert *Lohn* auf *NichtMann*, eine binäre Variable die 1 ist, falls die Person kein Mann ist und 0 für einen Mann. Bestimmen Sie die Regressionsergebnisse dieser Regression:

$$\widehat{Lohn} = \_\_\_\_\_\_ + \_\_\_\_\_\_ \times NichtMann, \quad R^2 = \_\_\_\_\_\_, \quad SER = \_\_\_\_\_\_.$$